

Autocorrelación

Anexo 1

1. Series estacionarias

Una de las ideas más importantes en el análisis de series temporales es la **estacionariedad**.

De manera intuitiva, una serie temporal es estacionaria cuando su **comportamiento estadístico se mantiene aproximadamente estable a lo largo del tiempo**.

Esto significa que, aunque los valores individuales de la serie cambien, sus principales características estadísticas, como la media, la variabilidad y la dependencia temporal, permanecen relativamente constantes.

Por ejemplo, una serie estacionaria puede presentar fluctuaciones alrededor de un nivel constante:

$$Y_t = \mu + \varepsilon_t,$$

donde μ representa un nivel medio constante y ε_t representa las fluctuaciones aleatorias alrededor de dicho nivel.

En cambio, una serie que presenta una tendencia creciente, cambios importantes en su variabilidad o modificaciones en su comportamiento a lo largo del tiempo generalmente no puede considerarse estacionaria.

1.1. Idea intuitiva

Una forma sencilla de pensar en la estacionariedad es preguntarnos:

Si observamos diferentes fragmentos de la serie, ¿parecen haber sido generados por el mismo mecanismo estadístico?

En una serie estacionaria, la respuesta debería ser aproximadamente afirmativa. Por ejemplo, si dividimos una serie en tres periodos,

$$\underbrace{Y_1, \dots, Y_{100}}_{\text{primer periodo}} \quad \underbrace{Y_{101}, \dots, Y_{200}}_{\text{segundo periodo}} \quad \underbrace{Y_{201}, \dots, Y_{300}}_{\text{tercer periodo}}$$

esperaríamos encontrar niveles medios y variabilidades similares en los tres bloques.




Figura 1: Ejemplo ilustrativo de una serie estacionaria y una serie no estacionaria.

1.2. Estacionariedad débil

En la práctica, normalmente trabajamos con el concepto de **estacionariedad débil** o **estacionariedad de segundo orden**.

Una serie temporal $\{Y_t\}$ es débilmente estacionaria si satisface las siguientes condiciones.

1.2.1. Media constante

La esperanza de la serie no depende del tiempo:

$$E(Y_t) = \mu$$

para todo t .

Es decir, la serie fluctúa alrededor de un nivel promedio constante.

1.2.2. Varianza constante

La varianza tampoco depende del tiempo:

$$\text{Var}(Y_t) = \sigma^2$$

para todo t .

Esto significa que la magnitud de las fluctuaciones de la serie permanece aproximadamente estable.

1.2.3. Autocovarianza dependiente únicamente del rezago

La covarianza entre dos observaciones de una serie estacionaria depende únicamente de la distancia temporal que existe entre ellas, llamada **rezago**, y no del momento particular en el que se encuentren.

Matemáticamente,

$$\text{Cov}(Y_t, Y_{t-k}) = \gamma(k),$$

donde $\gamma(k)$ se denomina **función de autocovarianza** en el rezago k .

La función de autocovarianza mide qué tanto varían conjuntamente dos observaciones de la misma serie que se encuentran separadas por k periodos.

Por ejemplo,

$$\gamma(1) = \text{Cov}(Y_t, Y_{t-1})$$

representa la autocovarianza entre observaciones consecutivas, mientras que

$$\gamma(2) = \text{Cov}(Y_t, Y_{t-2})$$

representa la autocovarianza entre observaciones separadas por dos periodos.

En una serie estacionaria, lo importante es la distancia entre las observaciones y no el instante particular en el que se realiza la comparación.

Por ejemplo,

$$\text{Cov}(Y_{10}, Y_9) = \gamma(1)$$

y

$$\text{Cov}(Y_{100}, Y_{99}) = \gamma(1),$$

ya que en ambos casos las observaciones están separadas por un periodo, es decir,

$$k = 1.$$

De manera similar,

$$\text{Cov}(Y_{20}, Y_{18}) = \text{Cov}(Y_{100}, Y_{98}) = \gamma(2),$$

porque en ambos casos el rezago es

$$k = 2.$$

Un caso particularmente importante ocurre cuando $k = 0$. En este caso,

$$\gamma(0) = \text{Cov}(Y_t, Y_t) = \text{Var}(Y_t),$$

por lo que, para una serie estacionaria,

$$\gamma(0) = \sigma^2.$$

Por lo tanto, una serie temporal $\{Y_t\}$ es débilmente estacionaria si satisface las siguientes condiciones:

$$\boxed{E(Y_t) = \mu}$$

$$\boxed{\text{Var}(Y_t) = \sigma^2}$$

y

$$\boxed{\text{Cov}(Y_t, Y_{t-k}) = \gamma(k)}$$

para todo t , donde $\gamma(k)$ depende únicamente del rezago k y no del tiempo t .

1.3. Relación con la autocorrelación

La estacionariedad es particularmente importante cuando estudiamos la función de autocorrelación.

Para una serie estacionaria,

$$\rho(k) = \text{Corr}(Y_t, Y_{t-k})$$

depende únicamente del rezago k .

Por lo tanto,

$$\rho(1)$$

describe la relación entre observaciones consecutivas independientemente del momento específico en el que se realice la comparación.

Esta propiedad permite interpretar de manera coherente los gráficos de ACF y PACF.

1.4. Ejemplos de series no estacionarias

Existen diferentes razones por las que una serie puede no ser estacionaria.

1.4.1. Tendencia

Una serie con tendencia puede escribirse, por ejemplo, como

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

Si

$$\beta_1 \neq 0,$$

la media de la serie cambia con el tiempo:

$$E(Y_t) = \beta_0 + \beta_1 t.$$

Por lo tanto, la serie no es estacionaria.

1.4.2. Variabilidad cambiante

Una serie también puede ser no estacionaria cuando su dispersión aumenta o disminuye con el tiempo.

Por ejemplo,

$$Y_t = \mu + \sigma_t \varepsilon_t,$$

donde σ_t cambia con t .

En este caso,

$$\text{Var}(Y_t) = \sigma_t^2,$$

por lo que la varianza no permanece constante.

1.4.3. Cambios estructurales

Otra posibilidad es que la serie presente un cambio importante en algún momento.

Por ejemplo,

$$E(Y_t) = \begin{cases} 5, & t \leq 100, \\ 10, & t > 100. \end{cases}$$

En este caso, el nivel promedio cambia y la serie completa no puede considerarse estacionaria.

1.5. ¿Por qué es importante la estacionariedad?

Muchos modelos clásicos de series temporales se construyen bajo el supuesto de que la estructura estadística de la serie permanece estable.

Esto es importante porque utilizamos el comportamiento observado en el pasado para intentar comprender o predecir el comportamiento futuro.

Si las propiedades de la serie cambian constantemente, las relaciones estimadas con datos anteriores pueden dejar de ser válidas posteriormente.

Por esta razón, antes de construir modelos como

$$AR(p), \quad MA(q), \quad ARMA(p, q),$$

es conveniente estudiar si la serie puede considerarse estacionaria.

Cuando una serie no es estacionaria, en algunos casos puede transformarse mediante operaciones como

diferenciación, transformaciones logarítmicas, eliminación de tendencia,

entre otras.

Posteriormente podremos evaluar formalmente la estacionariedad utilizando pruebas estadísticas como la **prueba de Dickey–Fuller aumentada (ADF)**.

2. Autocorrelación: ACF y PACF

Una característica importante de las series temporales es que las observaciones no necesariamente son independientes entre sí. En muchos problemas, el valor observado en un tiempo determinado puede estar relacionado con valores observados anteriormente.

Por ejemplo, si Y_t representa la temperatura registrada en el día t , es razonable esperar que la temperatura de hoy tenga cierta relación con la temperatura de ayer o incluso con la de hace varios días.

La **autocorrelación** permite cuantificar este tipo de dependencia temporal.

2.1. Función de autocorrelación (ACF)

Sea una serie temporal

$$Y_1, Y_2, \dots, Y_n.$$

La **función de autocorrelación**, conocida como ACF (*Autocorrelation Function*), mide la correlación entre la serie Y_t y una versión desplazada de ella misma Y_{t-k} .

La autocorrelación poblacional en el rezago k se define como

$$\rho(k) = \text{Corr}(Y_t, Y_{t-k}),$$

o equivalentemente,

$$\rho(k) = \frac{\text{Cov}(Y_t, Y_{t-k})}{\sqrt{\text{Var}(Y_t) \text{Var}(Y_{t-k})}}.$$

Cuando la serie es estacionaria, la varianza no depende del tiempo, por lo que

$$\text{Var}(Y_t) = \text{Var}(Y_{t-k}) = \gamma(0),$$

y entonces

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)},$$

donde

$$\gamma(k) = \text{Cov}(Y_t, Y_{t-k})$$

es la función de autocovarianza.

En una muestra, la autocorrelación en el rezago k puede estimarse mediante

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2},$$

donde

$$\bar{Y} = \frac{1}{n} \sum_{t=1}^n Y_t.$$

2.2. Interpretación de los rezagos

El valor de k recibe el nombre de **rezago** o *lag*.

Por ejemplo,

$$\rho(1) = \text{Corr}(Y_t, Y_{t-1})$$

mide la asociación entre una observación y la observación inmediatamente anterior.

De manera similar,

$$\rho(2) = \text{Corr}(Y_t, Y_{t-2})$$

mide la asociación con dos periodos de retraso.

En general,

$$-1 \leq \rho(k) \leq 1.$$

La interpretación es similar a la de cualquier coeficiente de correlación:

- Si $\rho(k)$ es cercano a 1, existe una fuerte asociación positiva entre observaciones separadas por k periodos.
- Si $\rho(k)$ es cercano a -1 , existe una fuerte asociación negativa.
- Si $\rho(k)$ es cercano a 0, existe poca asociación lineal para ese rezago.

Por definición,

$$\rho(0) = 1,$$

ya que cualquier variable tiene correlación perfecta consigo misma.

2.3. Función de autocorrelación parcial (PACF)

La ACF mide tanto las relaciones **directas** como las relaciones **indirectas** entre observaciones.

Para comprender este punto, supongamos que Y_t depende directamente de Y_{t-1} y que Y_{t-1} depende de Y_{t-2} .

Entonces podemos observar una correlación entre

$$Y_t \quad \text{y} \quad Y_{t-2},$$

aunque una parte importante de esta relación sea consecuencia de la influencia de Y_{t-1} .

La **función de autocorrelación parcial**, conocida como PACF (*Partial Auto-correlation Function*), mide la relación entre Y_t y Y_{t-k} después de eliminar el efecto lineal de los rezagos intermedios

$$Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}.$$

La autocorrelación parcial en el rezago k puede expresarse como

$$\phi_{kk} = \text{Corr}(Y_t, Y_{t-k} \mid Y_{t-1}, \dots, Y_{t-k+1}).$$

Por ejemplo, para $k = 2$,

$$\phi_{22} = \text{Corr}(Y_t, Y_{t-2} \mid Y_{t-1}).$$

Es decir, mide la relación entre Y_t y Y_{t-2} después de controlar el efecto de Y_{t-1} . Para el primer rezago no existen valores intermedios que eliminar, por lo que

$$\phi_{11} = \rho(1).$$

2.4. Diferencia entre ACF y PACF

De manera esquemática,

ACF: relación total entre Y_t y Y_{t-k}

mientras que

PACF: relación directa entre Y_t y Y_{t-k}

después de eliminar el efecto de los rezagos intermedios.

La ACF y la PACF son herramientas fundamentales para identificar la estructura temporal de una serie y son especialmente útiles en la construcción de modelos autorregresivos y ARIMA.

2.5. Ejemplo

Consideremos la siguiente serie temporal de 10 observaciones:

t	1	2	3	4	5	6	7	8	9	10
Y_t	2	3	4	3	5	6	5	7	8	9

Visualmente puede observarse una tendencia general creciente. Además, valores altos tienden a estar acompañados por valores altos en los periodos cercanos.

Primero calculamos la media:

$$\bar{Y} = \frac{2 + 3 + 4 + 3 + 5 + 6 + 5 + 7 + 8 + 9}{10}.$$

Por lo tanto,

$$\bar{Y} = \frac{52}{10} = 5,2.$$

2.5.1. Autocorrelación en el rezago 1

Para calcular r_1 utilizamos

$$r_1 = \frac{\sum_{t=2}^{10} (Y_t - \bar{Y})(Y_{t-1} - \bar{Y})}{\sum_{t=1}^{10} (Y_t - \bar{Y})^2}.$$

Las desviaciones respecto a la media son

t	1	2	3	4	5	6	7	8	9	10
$Y_t - \bar{Y}$	-3,2	-2,2	-1,2	-2,2	-0,2	0,8	-0,2	1,8	2,8	3,8

El denominador es

$$\sum_{t=1}^{10} (Y_t - \bar{Y})^2 = 10,24 + 4,84 + 1,44 + 4,84 + 0,04 + 0,64 + 0,04 + 3,24 + 7,84 + 14,44,$$

por lo que

$$\sum_{t=1}^{10} (Y_t - \bar{Y})^2 = 47,60.$$

Ahora calculamos los productos correspondientes al rezago 1:

$$\begin{aligned} \sum_{t=2}^{10} (Y_t - \bar{Y})(Y_{t-1} - \bar{Y}) &= (-2,2)(-3,2) + (-1,2)(-2,2) \\ &\quad + (-2,2)(-1,2) + (-0,2)(-2,2) \\ &\quad + (0,8)(-0,2) + (-0,2)(0,8) \\ &\quad + (1,8)(-0,2) + (2,8)(1,8) + (3,8)(2,8). \end{aligned}$$

Esto produce

$$\sum_{t=2}^{10} (Y_t - \bar{Y})(Y_{t-1} - \bar{Y}) = 27,76.$$

Por lo tanto,

$$r_1 = \frac{27,76}{47,60} \approx 0,583.$$

Así,

$$\boxed{r_1 \approx 0,58}$$

indica una autocorrelación positiva moderada entre observaciones consecutivas.

En otras palabras, cuando el valor de la serie en un periodo es relativamente alto, existe cierta tendencia a que el valor del periodo siguiente también sea alto.

2.5.2. Autocorrelación en el rezago 2

Ahora podemos comparar observaciones separadas por dos periodos:

$$(Y_3, Y_1), (Y_4, Y_2), (Y_5, Y_3), \dots, (Y_{10}, Y_8).$$

La autocorrelación muestral correspondiente es

$$r_2 = \frac{\sum_{t=3}^{10} (Y_t - \bar{Y})(Y_{t-2} - \bar{Y})}{\sum_{t=1}^{10} (Y_t - \bar{Y})^2}.$$

Para esta serie se obtiene aproximadamente

$$r_2 \approx 0,42.$$

Por lo tanto, todavía existe asociación positiva entre observaciones separadas por dos periodos, aunque es menor que la observada para el primer rezago.

2.5.3. ACF frente a PACF

Supongamos que encontramos

$$r_1 \approx 0,58$$

y

$$r_2 \approx 0,42.$$

La ACF indica que Y_t está relacionado tanto con Y_{t-1} como con Y_{t-2} .

Sin embargo, esto no significa necesariamente que Y_{t-2} tenga una influencia directa sobre Y_t .

Podría ocurrir que parte de la relación

$$Y_{t-2} \longrightarrow Y_t$$

se explique indirectamente por

$$Y_{t-2} \longrightarrow Y_{t-1} \longrightarrow Y_t.$$

La PACF en el rezago 2 elimina precisamente el efecto de Y_{t-1} y pregunta:

¿Sigue existiendo una relación importante entre Y_t y Y_{t-2} una vez que se ha considerado la información contenida en Y_{t-1} ?

Esta distinción es particularmente importante cuando utilizamos ACF y PACF para identificar posibles modelos de series temporales.

2.6. Interpretación gráfica

En la práctica, la ACF y la PACF suelen representarse mediante gráficos de barras para diferentes valores del rezago:

$$k = 1, 2, 3, \dots$$

Cada barra representa el valor de autocorrelación correspondiente a ese rezago. De manera general:

- La **ACF** ayuda a identificar durante cuántos periodos permanece la dependencia temporal.
- La **PACF** ayuda a identificar qué rezagos contienen información directa adicional sobre la serie.

Estas dos funciones serán especialmente útiles posteriormente para identificar modelos de la forma

$$AR(p), \quad MA(q),$$

y, de manera más general,

$$ARIMA(p, d, q).$$

3. Pruebas de estacionariedad: ADF y KPSS

La inspección gráfica de una serie temporal puede dar una primera idea sobre su estacionariedad, pero normalmente es conveniente complementar esta observación con pruebas estadísticas formales.

Dos de las pruebas más utilizadas son:

- la prueba **Augmented Dickey–Fuller (ADF)**,
- la prueba **KPSS** (*Kwiatkowski–Phillips–Schmidt–Shin*).

Estas pruebas son especialmente útiles porque plantean hipótesis nulas diferentes y, por lo tanto, pueden utilizarse de manera complementaria.

3.1. Prueba Augmented Dickey–Fuller (ADF)

La prueba **Augmented Dickey–Fuller** se utiliza para investigar si una serie temporal presenta una **raíz unitaria**.

La presencia de una raíz unitaria está asociada con un comportamiento no estacionario.

Para comprender la idea, consideremos primero un modelo autorregresivo de primer orden:

$$Y_t = \rho Y_{t-1} + \varepsilon_t,$$

donde ε_t representa un término aleatorio.

Si

$$|\rho| < 1,$$

el proceso puede ser estacionario.

En cambio, si

$$\rho = 1,$$

se obtiene

$$Y_t = Y_{t-1} + \varepsilon_t,$$

que corresponde a un paseo aleatorio y es un ejemplo clásico de una serie no estacionaria.

Restando Y_{t-1} en ambos lados,

$$Y_t - Y_{t-1} = (\rho - 1)Y_{t-1} + \varepsilon_t.$$

Definiendo

$$\Delta Y_t = Y_t - Y_{t-1}$$

y

$$\gamma = \rho - 1,$$

obtenemos

$$\Delta Y_t = \gamma Y_{t-1} + \varepsilon_t.$$

La prueba Dickey–Fuller analiza precisamente si

$$\gamma = 0.$$

Si $\gamma = 0$, entonces $\rho = 1$ y la serie tiene una raíz unitaria.

3.1.1. Hipótesis de la prueba ADF

La prueba ADF plantea las hipótesis

$$H_0 : \text{la serie presenta una raíz unitaria}$$

frente a

$$H_1 : \text{la serie no presenta una raíz unitaria.}$$

En términos prácticos,

$$\boxed{H_0 : \text{serie no estacionaria}}$$

y

$$\boxed{H_1 : \text{serie estacionaria}}$$

bajo la especificación utilizada en la prueba.

3.1.2. ¿Por qué se llama “Augmented”?

La versión original de Dickey–Fuller supone que los errores no presentan autocorrelación.

Sin embargo, en series temporales reales esto puede no cumplirse.

La prueba Augmented Dickey–Fuller incorpora rezagos de las primeras diferencias de la serie:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^p \delta_i \Delta Y_{t-i} + \varepsilon_t.$$

En esta expresión:

- α representa una constante;
- βt representa una posible tendencia determinista;
- Y_{t-1} permite evaluar la presencia de una raíz unitaria;
- ΔY_{t-i} representa rezagos de las primeras diferencias;
- p representa el número de rezagos incorporados;
- ε_t representa el término de error.

Los términos rezagados

$$\Delta Y_{t-1}, \Delta Y_{t-2}, \dots, \Delta Y_{t-p}$$

se agregan para capturar la posible autocorrelación de los errores.

3.1.3. Interpretación mediante el valor p

La decisión puede realizarse utilizando el valor p .

Para un nivel de significancia

$$\alpha = 0,05,$$

si

$$p\text{-value} < 0,05,$$

se rechaza H_0 .

Por lo tanto, existe evidencia a favor de que la serie no presenta una raíz unitaria y puede considerarse estacionaria bajo el modelo especificado.

En cambio, si

$$p\text{-value} \geq 0,05,$$

no se rechaza H_0 .

En este caso no existe evidencia suficiente para descartar la presencia de una raíz unitaria.

Es importante señalar que

no rechazar $H_0 \neq$ demostrar que H_0 es verdadera.

3.2. Prueba KPSS

La prueba **KPSS** fue propuesta por Kwiatkowski, Phillips, Schmidt y Shin.

A diferencia de la prueba ADF, la prueba KPSS toma como hipótesis nula la **estacionariedad** de la serie.

Una representación conceptual utilizada en esta prueba es

$$Y_t = \xi t + r_t + \varepsilon_t,$$

donde

- ξt representa una tendencia determinista;
- r_t representa un componente de paseo aleatorio;
- ε_t representa un componente estacionario.

El componente r_t puede escribirse como

$$r_t = r_{t-1} + u_t,$$

donde

$$u_t \sim (0, \sigma_u^2).$$

Si

$$\sigma_u^2 = 0,$$

el componente de paseo aleatorio desaparece.

En ese caso, la serie puede considerarse estacionaria alrededor de un nivel o de una tendencia, dependiendo de la especificación utilizada.

3.2.1. Hipótesis de la prueba KPSS

La prueba KPSS plantea

$$H_0 : \text{la serie es estacionaria}$$

frente a

$$H_1 : \text{la serie no es estacionaria.}$$

Por lo tanto,

$$\boxed{H_0 : \text{estacionariedad}}$$

y

$$\boxed{H_1 : \text{no estacionariedad.}}$$

Esto es exactamente lo contrario de lo que ocurre en la prueba ADF.

3.2.2. Estadístico KPSS

La prueba se construye a partir de las sumas parciales de los residuos de un modelo ajustado.

Si e_t representa el residuo estimado, se define

$$S_t = \sum_{i=1}^t e_i.$$

El estadístico KPSS tiene la forma

$$\text{KPSS} = \frac{\sum_{t=1}^n S_t^2}{n^2 \hat{\sigma}^2},$$

donde $\hat{\sigma}^2$ es una estimación de la varianza de largo plazo de los errores.

Valores grandes del estadístico proporcionan evidencia en contra de la hipótesis nula de estacionariedad.

3.2.3. Interpretación mediante el valor p

Utilizando nuevamente un nivel de significancia de

$$\alpha = 0,05,$$

si

$$p\text{-value} < 0,05,$$

se rechaza H_0 .

Por lo tanto, existe evidencia en contra de la estacionariedad de la serie.

En cambio, si

$$p\text{-value} \geq 0,05,$$

no se rechaza H_0 y los datos son compatibles con la hipótesis de estacionariedad.

3.3. ADF y KPSS como pruebas complementarias

La principal diferencia entre ambas pruebas se encuentra en sus hipótesis nulas:

Prueba	H_0
ADF	La serie tiene raíz unitaria
KPSS	La serie es estacionaria

Por esta razón, es común utilizar ambas pruebas de manera conjunta.

Los posibles resultados pueden resumirse de la siguiente manera:

ADF	KPSS	Interpretación
Rechaza H_0	No rechaza H_0	Evidencia consistente con estacionariedad
No rechaza H_0	Rechaza H_0	Evidencia consistente con no estacionariedad
Rechaza H_0	Rechaza H_0	Resultados contradictorios
No rechaza H_0	No rechaza H_0	Resultados no concluyentes

Así, una conclusión especialmente clara de estacionariedad se obtiene cuando

$$\boxed{\text{ADF rechaza } H_0 \quad \text{y} \quad \text{KPSS no rechaza } H_0.}$$

Por el contrario, una fuerte evidencia de no estacionariedad se obtiene cuando

$$\boxed{\text{ADF no rechaza } H_0 \quad \text{y} \quad \text{KPSS rechaza } H_0.}$$

3.4. Importancia de la especificación

Tanto la prueba ADF como la prueba KPSS pueden aplicarse bajo diferentes supuestos.

Por ejemplo, una serie puede analizarse suponiendo:

- ausencia de constante y tendencia;
- presencia de una constante;
- presencia de una constante y una tendencia determinista.

La elección debe realizarse de acuerdo con las características de la serie.

Una serie que fluctúa alrededor de un nivel constante puede requerir una especificación diferente de una serie que presenta una tendencia determinista.

Por esta razón, las pruebas estadísticas deben interpretarse junto con:

- la gráfica de la serie temporal;
- el comportamiento de su media y varianza;
- los gráficos de ACF y PACF;
- el contexto del problema analizado.

Las pruebas ADF y KPSS proporcionan evidencia estadística importante, pero no deben utilizarse de manera aislada.