

Planeación de Tópicos Selectos de Matemáticas Aplicadas II

Ciencia de Datos para la Modelación de Fenómenos Temporales y Ambientales

I. Información general

- **Nombre de la UEA:** Tópicos Selectos de Matemáticas Aplicadas II.
- **Nombre del profesor:** Dr. Juan Alberto Martínez Cadena.
- **Modalidad:** Presencial.
- **Duración:** 11 semanas.
- **Herramienta principal:** Python mediante Jupyter Notebook.

II. Descripción del curso

La UEA tiene como propósito profundizar en el uso de herramientas de ciencia de datos, modelación estadística y aprendizaje automático para el análisis de conjuntos de datos reales con estructura temporal, multivariada y, cuando corresponda, espacial.

El curso está diseñado como continuación de una formación previa en programación con Python, estadística descriptiva, visualización de datos y herramientas básicas de análisis estadístico. Por esta razón, el contenido se concentra en técnicas de mayor nivel relacionadas con series temporales, ingeniería de características, reducción de dimensión, clustering, aprendizaje supervisado, modelos probabilísticos, validación temporal e interpretación de modelos.

Durante el curso se proporcionarán diferentes conjuntos de datos reales relacionados, entre otros, con:

- incidencia epidemiológica;
- dengue y otros fenómenos de salud;
- contaminación atmosférica;
- variables meteorológicas;
- fenómenos ambientales;
- energía;

Cada alumno podrá seleccionar uno o varios conjuntos de datos de acuerdo con sus intereses académicos y desarrollar sobre ellos las actividades del curso.

El flujo general que guiará la UEA será:

Datos → Estructura temporal → Características → Modelación → Validación → Interpretación

III. Objetivo general

Desarrollar en el alumno la capacidad para diseñar, implementar y evaluar un flujo reproducible de análisis de datos científicos, con especial énfasis en fenómenos temporales y multivariados, utilizando herramientas estadísticas, modelos probabilísticos y técnicas de aprendizaje automático.

IV. Objetivos específicos

Al finalizar el curso, el alumno será capaz de:

1. Identificar y representar adecuadamente la estructura temporal y multivariada de un conjunto de datos real.
2. Construir series temporales y paneles mediante diferentes resoluciones temporales y espaciales.
3. Diseñar características derivadas mediante rezagos, ventanas móviles, diferencias, tasas de cambio y variables de calendario.
4. Analizar tendencia, estacionalidad, autocorrelación y estacionariedad en series temporales.
5. Aplicar técnicas de reducción de dimensión y métodos de clustering para identificar estructuras latentes en los datos.
6. Formular problemas de regresión, clasificación y pronóstico a partir de conjuntos de datos reales.
7. Implementar y comparar modelos estadísticos y de aprendizaje automático.
8. Diseñar esquemas de validación apropiados para datos independientes, agrupados y temporales.
9. Identificar y prevenir problemas de *data leakage*.
10. Evaluar modelos mediante métricas apropiadas al tipo de problema.

11. Analizar la importancia de variables y la interpretabilidad de los modelos.
12. Integrar los diferentes elementos del análisis en un estudio reproducible mediante Jupyter Notebook.

V. Contenido del curso

1. Estructura y preparación de datos temporales

Manejo de fechas y frecuencias temporales

- Índices temporales mediante `DatetimeIndex`.
- Frecuencias temporales.
- Series regulares e irregulares.
- Remuestreo mediante `resample`.
- Agregación horaria, diaria, semanal y mensual.
- Elección apropiada de funciones de agregación.
- Detección de fechas faltantes.
- Construcción de calendarios temporales completos.
- Alineación de series.

Series multivariadas y datos tipo panel

Se estudiarán estructuras de la forma Y_t , para una serie temporal univariada;

$$\mathbf{X}_t = (X_{1,t}, X_{2,t}, \dots, X_{p,t}),$$

para una serie temporal multivariada; y $Y_{i,t}$, para datos tipo panel, donde i representa una unidad y t el tiempo.

- Formato largo y formato ancho.
- Unidad temporal y unidad espacial.
- Paneles balanceados y no balanceados.
- Integración de múltiples fuentes de datos.
- Series por estado, municipio, estación o región.
- Consistencia temporal entre variables.

2. Ingeniería de características temporales

Rezagos, diferencias y tasas de cambio

Se construirán variables rezagadas:

$$X_{t-1}, X_{t-2}, \dots, X_{t-p},$$

así como diferencias:

$$\Delta X_t = X_t - X_{t-1}.$$

Contenido:

- Rezagos temporales.
- Diferencias absolutas.
- Tasas de cambio.
- Transformaciones relativas.
- Interpretación de efectos retardados.
- Relación entre variable objetivo y covariables rezagadas.

Ventanas móviles y variables temporales

Se estudiarán características construidas mediante ventanas temporales, por ejemplo:

$$\overline{X}_t^{(k)} = \frac{1}{k} \sum_{j=0}^{k-1} X_{t-j}.$$

Se considerarán:

- medias móviles;
- medianas móviles;
- desviaciones estándar móviles;
- máximos y mínimos móviles;
- cuantiles móviles;
- acumulados;

- amplitudes;
- tendencia local;
- variables indicadoras de calendario.

También se introducirá la codificación cíclica mediante:

$$x_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad x_{\cos} = \cos\left(\frac{2\pi t}{T}\right).$$

Se introducirá el concepto de *data leakage* y la regla fundamental de que una característica utilizada para predecir el futuro únicamente puede construirse con información disponible hasta el instante de predicción.

3. Caracterización de series temporales

Tendencia y estacionalidad

- Tendencia.
- Ciclos.
- Estacionalidad.
- Descomposición clásica.
- Descomposición STL.
- Interpretación de componentes temporales.

Se considerará la representación:

$$Y_t = T_t + S_t + R_t,$$

donde T_t representa la tendencia, S_t la componente estacional y R_t el residuo.

Dependencia temporal y estacionariedad

- Autocorrelación.
- Función de autocorrelación (ACF).
- Función de autocorrelación parcial (PACF).
- Dependencia entre observaciones temporales.

- Concepto de estacionariedad.
- Prueba de Dickey–Fuller aumentada (ADF).
- Diferenciación de series.
- Introducción a la prueba KPSS como complemento.

4. Representación multivariada y clustering

Estandarización y reducción de dimensión

Se estudiará la transformación:

$$Z_j = \frac{X_j - \mu_j}{\sigma_j},$$

así como:

- importancia de la escala;
- matrices de covarianza;
- correlación entre predictores;
- análisis de componentes principales (PCA);
- varianza explicada;
- selección del número de componentes;
- interpretación de componentes principales.

Sesión 8. Clustering

- Concepto de aprendizaje no supervisado.
- Distancias entre observaciones.
- k -means.
- Clustering jerárquico.
- Dendrogramas.
- Métodos de enlace.
- Índice silhouette.

- Selección del número de clústeres.
- Interpretación de grupos.
- Introducción a modelos Gaussian Mixture Model (GMM).

VI. Actividad 1

Entrega: Viernes de Semana 4

Título: Caracterización temporal y multivariada de un conjunto de datos

El alumno seleccionará un conjunto de datos del repositorio del curso y desarrollará un notebook que incluya:

1. Descripción del conjunto de datos y del fenómeno estudiado.
2. Identificación de la unidad de observación.
3. Construcción y revisión de la estructura temporal.
4. Análisis de cobertura y fechas faltantes.
5. Transformación a una resolución temporal apropiada.
6. Construcción de variables rezagadas y/o móviles.
7. Análisis de tendencia y estacionalidad.
8. Análisis de autocorrelación.
9. Caracterización multivariada de las variables.
10. Aplicación de PCA y/o clustering cuando resulte pertinente.
11. Interpretación de los resultados obtenidos.
12. Conclusiones.

5. Introducción al aprendizaje supervisado

Formulación de problemas predictivos

Se distinguirán tres problemas fundamentales.

Regresión:

$$Y = f(\mathbf{X}) + \epsilon.$$

Clasificación:

$$P(Y = 1 \mid \mathbf{X}).$$

Pronóstico:

$$\hat{Y}_{t+h} = f(\mathbf{X}_t, \mathbf{X}_{t-1}, \dots).$$

Contenido:

- Variable objetivo.
- Variables predictoras.
- Conjunto de entrenamiento.
- Conjunto de validación.
- Conjunto de prueba.
- Modelos baseline.
- Sobreajuste y subajuste.
- Generalización.

Modelos lineales y clasificación

- Regresión lineal como modelo baseline.
- Interpretación de coeficientes.
- Regresión logística.
- Probabilidad de pertenencia a una clase.
- Umbral de clasificación.

En regresión logística:

$$P(Y = 1 \mid \mathbf{X}) = \frac{1}{1 + \exp \left[- \left(\beta_0 + \boldsymbol{\beta}^T \mathbf{X} \right) \right]}.$$

6. Modelos basados en árboles

Semana 6

Árboles de decisión y Random Forest

- Árboles de decisión.
- Particiones recursivas.
- Profundidad del árbol.
- Sobreajuste.
- Criterios de partición.
- Random Forest.
- Bootstrap.
- Selección aleatoria de variables.
- Importancia de características.

Para un ensamble de B modelos se puede representar la predicción como:

$$\hat{f}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(\mathbf{x}).$$

Gradient Boosting

- Concepto de boosting.
- Construcción secuencial de modelos.
- Corrección de errores.
- Gradient Boosting.
- Introducción a XGBoost.
- Principales hiperparámetros.
- Comparación entre modelos.

7. Evaluación y validación de modelos

Métricas de evaluación

Para problemas de regresión se estudiarán, entre otras:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

y

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

También se revisará R^2 y sus limitaciones.

Para problemas de clasificación:

- matriz de confusión;
- accuracy;
- precision;
- recall;
- especificidad;
- F1-score;
- curva ROC;
- ROC-AUC;
- curva Precision–Recall;
- PR-AUC;
- desbalance de clases.

Validación y prevención de *data leakage*

- División entrenamiento–prueba.
- Validación cruzada.
- K -Fold.
- Stratified K -Fold.

- Group K -Fold.
- Dependencia entre observaciones.
- Fugas de información.
- Validación de datos temporales.

Para datos temporales se estudiarán esquemas como:

$$\underbrace{1, \dots, t_1}_{\text{entrenamiento}} \longrightarrow \underbrace{t_1 + 1, \dots, t_1 + h}_{\text{prueba}},$$

seguido de

$$\underbrace{1, \dots, t_2}_{\text{entrenamiento}} \longrightarrow \underbrace{t_2 + 1, \dots, t_2 + h}_{\text{prueba}}.$$

Se introducirán:

- *rolling-origin*;
- ventana expansiva;
- ventana móvil;
- backtesting.

VII. Actividad 2

Título: Construcción y validación de modelos

El alumno formulará un problema de modelación apropiado para el conjunto de datos seleccionado.

Dependiendo de la naturaleza del problema podrá trabajar con:

- regresión;
- clasificación;
- pronóstico;
- clustering, cuando el problema sea genuinamente no supervisado.

El notebook deberá incluir:

1. Formulación de una pregunta de modelación.
2. Definición de la variable objetivo, cuando corresponda.
3. Selección y construcción de predictores.
4. Definición de un modelo baseline.
5. Implementación de al menos dos modelos.
6. Diseño del esquema de validación.
7. Selección de métricas apropiadas.
8. Comparación cuantitativa entre modelos.
9. Análisis de los principales errores.
10. Interpretación de resultados.
11. Conclusiones.

8. Modelos probabilísticos e incertidumbre

Modelos para datos de conteo

Se estudiarán modelos especialmente útiles cuando la variable respuesta corresponde a casos, eventos o frecuencias.

Para una variable Poisson:

$$Y \sim \text{Poisson}(\lambda),$$

con

$$E(Y) = \text{Var}(Y) = \lambda.$$

Contenido:

- Distribución Poisson.
- Modelos lineales generalizados.
- Función de enlace logarítmica.
- GLM Poisson.
- Interpretación de coeficientes.
- Diagnóstico de ajuste.

Sobredispersión e incertidumbre

- Concepto de sobredispersión.
- Diagnóstico de sobredispersión.
- Distribución binomial negativa.
- Comparación Poisson vs. binomial negativa.
- Predicción puntual.
- Intervalos de predicción.
- Introducción al pronóstico probabilístico.

En un modelo NB2:

$$\text{Var}(Y) = \mu + \alpha\mu^2.$$

9. Eventos extremos, anomalías y cambios de régimen

Detección de anomalías y eventos extremos

- Definición de valores extremos.
- Umbrales mediante percentiles.
- Z-score.
- Métodos robustos.
- Mediana.
- MAD.
- Rango intercuartílico.
- Isolation Forest.
- Diferencia entre valor extremo, anomalía y evento de interés.

Se podrá definir, por ejemplo:

$$Z_t = \begin{cases} 1, & X_t > u, \\ 0, & X_t \leq u. \end{cases}$$

Cambios de régimen

- Concepto de cambio estructural.
- CUSUM.
- Detección de puntos de cambio.
- Segmentación temporal.
- Introducción a estados latentes.
- Introducción conceptual a modelos ocultos de Markov.
- Aplicaciones a fenómenos ambientales y epidemiológicos.

10. Interpretabilidad y diseño de experimentos

Interpretabilidad de modelos

- Interpretación de coeficientes.
- Importancia de variables.
- Limitaciones de la importancia basada en impureza.
- Permutation importance.
- Dependencia parcial.
- Introducción a SHAP.
- Identificación de variables relevantes.

Comparaciones, ablación y robustez

Se estudiará cómo diseñar comparaciones que permitan responder preguntas metodológicas, por ejemplo:

modelo simple vs. modelo complejo,

sin variables meteorológicas vs. con variables meteorológicas,

sin rezagos vs. con rezagos,

o

modelo global vs. modelos especializados.

Contenido:

- Modelos baseline.
- Estudios de ablación.
- Análisis de sensibilidad.
- Robustez de resultados.
- Comparaciones controladas.
- Selección del modelo final.

11. Integración y comunicación de resultados

Integración del análisis

La sesión se dedicará a integrar los componentes desarrollados durante el curso:

- planteamiento del problema;
- descripción de datos;
- metodología;
- resultados;
- tablas;
- figuras;
- comparación de modelos;
- interpretación;
- limitaciones;
- conclusiones;
- reproducibilidad.

Presentación y discusión de resultados

Cada alumno presentará de manera breve el estudio desarrollado durante el curso, incluyendo:

1. fenómeno estudiado;
2. pregunta planteada;
3. conjunto de datos;
4. metodología;
5. principales resultados;
6. limitaciones;
7. posibles extensiones del análisis.

VIII. Actividad 3

Entrega: Semana 11

Título: Proyecto integrador de ciencia de datos

El objetivo de la actividad será integrar las herramientas del curso en un análisis completo y reproducible.

El flujo esperado será:

Problema → Datos → Caracterización → Features → Modelo → Validación → Interpretación
--

El notebook deberá contener:

1. Planteamiento y justificación del problema.
2. Descripción del conjunto de datos.
3. Definición de la unidad de análisis.
4. Preparación de los datos.
5. Análisis exploratorio y temporal.
6. Construcción de características.
7. Definición de un modelo baseline.
8. Implementación de uno o más modelos principales.

9. Diseño adecuado de la validación.
10. Selección de métricas.
11. Comparación de resultados.
12. Interpretación del modelo.
13. Análisis de errores.
14. Discusión de limitaciones.
15. Conclusiones.
16. Posibles extensiones del estudio.

IX. Evaluación

La evaluación estará basada en tres actividades desarrolladas mediante Jupyter Notebook.

Actividad	Ponderación
Actividad 1. Caracterización temporal y multi-variada	30 %
Actividad 2. Construcción y validación de modelos	30 %
Actividad 3. Proyecto integrador de ciencia de datos	40 %
Total	100 %

X. Lineamientos para los notebooks

Los notebooks entregados deberán documentar no solamente el código utilizado, sino también el razonamiento metodológico y la interpretación de los resultados.

Se recomienda que el desarrollo siga la estructura:

Celda Markdown → Celda de código → Celda Markdown de interpretación.

Antes de cada bloque importante de código deberá explicarse:

- qué se realizará;

- por qué se realizará;
- qué concepto estadístico o matemático se está utilizando;
- qué resultado se espera observar.

Después de obtener los resultados, deberán interpretarse mediante texto y no únicamente mostrarse tablas, métricas o figuras.

Se considerarán como parte de la evaluación:

- claridad del análisis;
- calidad y reproducibilidad del código;
- justificación metodológica;
- interpretación correcta de resultados;
- calidad de las visualizaciones;
- coherencia entre pregunta, método y conclusiones.

XI. Criterios para la asignación de la calificación

La calificación numérica final se transformará de acuerdo con los siguientes intervalos:

- Menos de 6: **NA**.
- De 6 a menos de 7.6: **S**.
- De 7.6 a menos de 8.6: **B**.
- De 8.6 a 10: **MB**.

XII. Bibliografía

1. Hyndman, R. J. y Athanasopoulos, G., *Forecasting: Principles and Practice*, OTexts.
2. James, G., Witten, D., Hastie, T. y Tibshirani, R., *An Introduction to Statistical Learning*, Springer.
3. Hastie, T., Tibshirani, R. y Friedman, J., *The Elements of Statistical Learning*, Springer.
4. Bishop, C. M., *Pattern Recognition and Machine Learning*, Springer.
5. Murphy, K. P., *Machine Learning: A Probabilistic Perspective*, MIT Press.

6. McCullagh, P. y Nelder, J. A., *Generalized Linear Models*, Chapman & Hall/CRC.
7. McKinney, W., *Python for Data Analysis*, O'Reilly Media.
8. VanderPlas, J., *Python Data Science Handbook*, O'Reilly Media.
9. Müller, A. C. y Guido, S., *Introduction to Machine Learning with Python*, O'Reilly Media.